Inteligencia Artificial aplicada a las Finanzas

Análisis y gestión de riesgos financieros

Jean Taipe Chávez · Quantmetrics

Universidad Nacional Autónoma de México (UNAM)
5.ª Semana Financiera de la CAFE

14 de octubre de 2026



Ruta del taller

Bloque	Contenido
1	Bases: riesgo financiero, VaR e IA en palabras simples
2	Laboratorio 1: riesgo de mercado
3	Laboratorio 2: riesgo de crédito
4	LLMs como copiloto del analista
5	Riesgo de modelo y cierre

No se necesita experiencia previa: partimos desde cero.

¿Qué es el riesgo financiero?

Idea central

Es la posibilidad de **perder dinero** porque el futuro no es lo que esperábamos.

Ejemplo 1: invertir

Compras acciones con tus ahorros. Si el precio baja, pierdes valor.

Ejemplo 2: prestar

Le prestas dinero a alguien. Si no te paga, pierdes lo prestado.

Gestionar riesgo es **medirlo antes de que ocurra**.

Los cuatro tipos de riesgo más comunes

Mercado
Cambian precios, tasas o tipo de cambio

Crédito
El deudor no paga

Liquidez
No puedo vender sin perder valor

Operacional
Fallan personas, procesos o sistemas

Hoy trabajaremos **mercado** y **crédito**.

Dos números para describir un activo

Rendimiento

Cuánto subió o bajó el precio de un día a otro, en porcentaje.

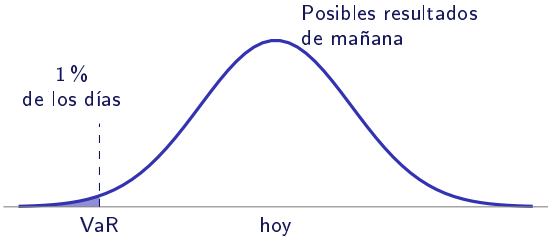
$$r_t = 100 \ln\left(\frac{P_t}{P_{t-1}}\right)$$

Volatilidad

Qué tanto se mueve el rendimiento. Más volatilidad, más incertidumbre y más riesgo.

La volatilidad **no es constante**: hay épocas tranquilas y épocas agitadas.

VaR: ¿cuánto podría perder en un mal día?



Lectura

Con 99 % de confianza, mañana **no perderemos más de** el VaR.

Ejemplo ilustrativo

Cartera de 1 000 000 y VaR de 2 %: la pérdida en un día no superaría 20 000 en 99 de cada 100 días.

La matemática del VaR

Definición: un cuantil de la pérdida

$$P\big(L_{t+1} > \mathrm{VaR}_\alpha\big) = 1 - \alpha, \qquad \mathrm{VaR}^{99\%}_{t+1} = -\big(\mu + \sigma_{t+1}\, q_{0{,}01}\big)$$

GARCH(1,1): volatilidad en rachas

$$\sigma^2_{t+1} = \omega + \alpha\, \varepsilon^2_t + \beta\, \sigma^2_t$$

El choque de hoy y la volatilidad de ayer determinan la de mañana.

Random Forest: aprende $|r|$

$$\hat{\sigma}_{t+1} \approx E\big[\,|r_{t+1}| \;\big|\; \mathcal{F}_t\big]\sqrt{\pi/2}$$

Predice el tamaño del movimiento con información hasta t.

Riesgo de crédito: ¿pagará o no pagará?

Idea

Un **scoring** es una nota que resume la probabilidad de que un cliente **no pague**.

Qué se mira

Ingreso, deudas, historial de pagos, antigüedad, uso de la línea de crédito.

Para qué sirve

Aprobar o rechazar, fijar tasas y límites, y reservar dinero para posibles pérdidas.

¿Qué es la IA, y qué es aprender de los datos?

Programar reglas

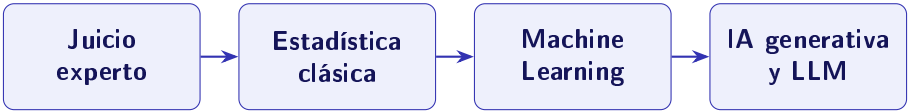
Una persona escribe: "si la deuda supera el 40 % del ingreso, rechazar".

Aprender de los datos

El modelo revisa miles de casos pasados y **descubre solo** qué patrones anticipan un impago.

El **machine learning** es esto. Los **LLM** (ChatGPT, Claude, Gemini) aprenden del lenguaje y trabajan con texto.

De la regla al aprendizaje: cómo evolucionó la gestión del riesgo



Cada etapa no borra a la anterior: la **complementa**.

Cuatro frentes donde la IA ya cambia las finanzas

Riesgo de crédito

Scoring con ML y variables alternativas

Riesgo de mercado

Volatilidad, VaR y escenarios con ML

Fraude y anomalías

Patrones atípicos en tiempo real

Asistentes con LLM

Lectura de reportes, normativa y noticias

Flujo de trabajo: lo que haremos de punta a punta



Precios y cartera $\rightarrow$ *features* $\rightarrow$ clásico vs. ML $\rightarrow$ backtesting y explicabilidad $\rightarrow$ límites y alertas

Laboratorio 1: tres maneras de estimar el VaR

Enfoque	**En palabras simples**	**Límite**
Histórico	Mira los últimos 250 días tal cual	Reacciona tarde
GARCH	Modelo que sabe que la volatilidad llega en rachas	Forma fija
Random Forest	Muchos árboles de decisión votan la volatilidad de mañana	Menos transparente

Los tres se comparan con datos que el modelo **no vio**.

Pasamos al notebook: Laboratorio 1

Qué haremos en el notebook

1. Descargar precios reales de Yahoo Finance
2. Calcular el VaR con los tres enfoques
3. Comparar violaciones y leer la prueba de Kupiec

Aquí cambiamos de pantalla: **código y resultados en vivo**.

¿Cómo sabemos si un VaR es bueno? Backtesting

Idea

Un VaR al 99 % debería fallar **1 de cada 100 días**. En 750 días esperamos unas 7 o 8 violaciones.

Prueba de Kupiec

Compara las violaciones observadas con las esperadas. Si el p-valor es mayor que 0,05, el modelo es consistente.

$$LR_{POF} = -2 \ln \frac{(1-p)^{n-x}\, p^{x}}{(1-\hat{p})^{n-x}\, \hat{p}^{x}} \sim \chi^2_1, \quad p = 0{,}01,\ \hat{p} = x/n$$

Laboratorio 2: scoring de crédito

Datos

1 000 clientes reales de un banco (*German Credit*): monto, plazo, edad, historial, ahorros y empleo. Objetivo: *mora*.

Qué comparamos

Regresión logística (referencia) frente a *gradient boosting*, con AUC y KS en datos de prueba.

El ML gana cuando hay **no linealidades e interacciones**.

La matemática del scoring

Regresión logística

$$P(\text{default} \mid x) = \frac{1}{1 + e^{-(\beta_0 + \beta^\top x)}}$$

Gradient boosting

$$F_m(x) = F_{m-1}(x) + \nu\, h_m(x)$$

Cada árbol h_m corrige el error del anterior; ν es la tasa de aprendizaje.

Métricas de discriminación

$$\mathrm{AUC} = P\left(s_{\text{malo}} > s_{\text{bueno}}\right)$$

$$\mathrm{KS} = \max_s \left| F_{\text{malo}}(s) - F_{\text{bueno}}(s) \right|$$

Explicabilidad (SHAP)

$$f(x) = \phi_0 + \sum_{j=1}^{p} \phi_j(x)$$

Pasamos al notebook: Laboratorio 2

Qué haremos en el notebook

1. Cargar la base de clientes reales y explorarla
2. Entrenar logística y gradient boosting
3. Explicar qué variables pesan en cada decisión

Aquí cambiamos de pantalla: **código, fórmulas y resultados en vivo**.

LLMs como copiloto del analista

Demo en vivo

- Resumir un reporte o circular normativa
- Explicar resultados de un modelo
- Generar y depurar código de backtesting

Buenas prácticas

- Comparar ChatGPT, Claude y Gemini con el mismo *prompt*
- Verificar cada cifra y cada cita
- Nunca subir datos de clientes

El LLM acelera al analista; la responsabilidad sigue siendo humana.

Riesgo de modelo: lo que separa una demo de un sistema confiable

- **Validación independiente** y backtesting continuo
- **Explicabilidad** de cada decisión
- **Sesgo y equidad** en variables y resultados
- **Trazabilidad:** versiones de datos y modelos
- **Privacidad** y seguridad de la información
- **Monitoreo** de deriva en producción

Referencia internacional: guía SR 11-7 de la Reserva Federal sobre gestión del riesgo de modelo.

Tres ideas para llevarte

1. La IA complementa al modelo clásico, no lo reemplaza.
2. Sin validación y explicabilidad no hay modelo confiable.
3. El valor está en la decisión de riesgo, no en el algoritmo.

Gracias

¿Preguntas?

